Power BI

Préparer des données analytiques

DataBird

Sommaire

Préparer des données analytiques

1. **Avant d'ouvrir Power BI, que faire ?**
2. **Gestion des données dans Power BI**
3. **Étapes de la préparation de données**
   - **3.1.** Transformer des données
   - **3.2.** Créer des colonnes
   - **3.3.** Créer des colonnes à l'aide d'IA
   - **3.4.** Concaténer des tables
   - **3.5.** Merge
   - **3.6.** Transposer, dépivoter, pivoter
4. **Modèle en étoile**

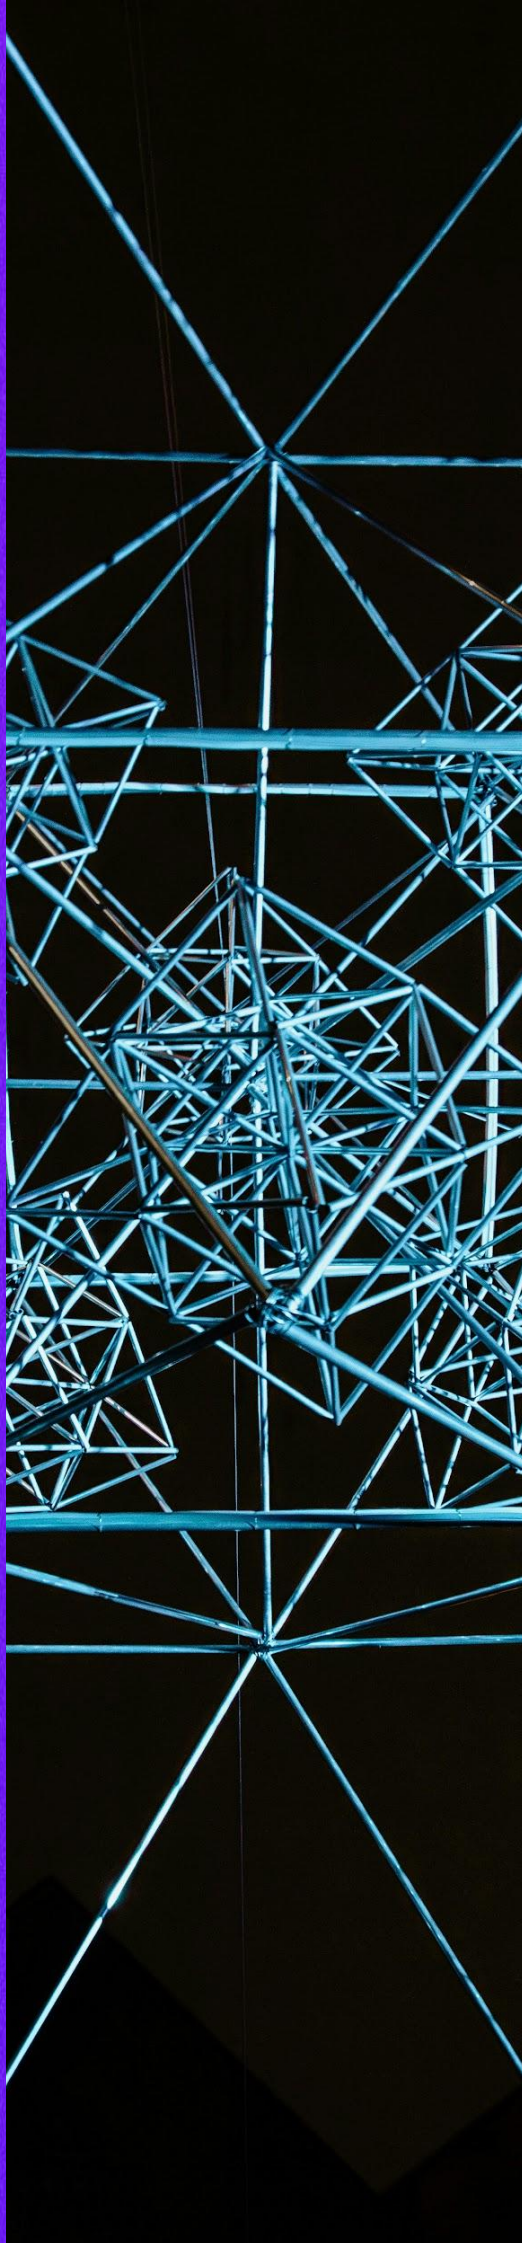

1. Avant d'ouvrir Power BI, que faire ?

Il y a 3 grandes étapes par lesquelles passer avant même d'ouvrir Power BI :

1. Savoir d'où l'on part : poser le contexte (qu'est-ce que j'ai à ma disposition ?)
2. Savoir où l'on va : établir une maquette visuelle pour avoir un aperçu du résultat final
3. Savoir comment on va y arriver : établir et étudier les sources de données

2. Gestion des données dans Power BI

Voici les principales sources de données :

- Bases de données relationnelles (ex. serveurs SQL).
- Fichiers plats (ex. Excel, CSV).
- Services cloud (ex. AWS, Azure, Google Cloud).
- Applications métiers (ex. SharePoint, Google Analytics, Salesforce).
- Bases de données NoSQL (ex. JSON, médias sociaux, données non structurées).

Les différents modes de stockage dans Power BI :

- Mode d'importation : importation et stockage direct des données dans le fichier Power BI, utilisé dans la majorité des cas.
- Direct Query : Accès direct aux données sans les importer, utile pour les grandes bases de données et pour une sécurité accrue.
- Dual : Combinaison des modes d'importation et Direct Query, permettant à Power BI de choisir le meilleur mode pour chaque table.

DataBird 2024 ©copyright

3. Étapes de la préparation de données

3.1 Transformer des données

C'est grâce à Power Query que tu vas pouvoir préparer et transformer tes données de manière méthodique. Voici les points clés :

- Préparation des données
  - Comprendre les données : examine les données horizontalement et verticalement pour comprendre leur contenu et structure.
  - Réduire la granularité : élimine les colonnes et les lignes inutiles pour alléger les données.
- Transformation des données dans Power Query
  - Renomme les requêtes pour une meilleure clarté.
  - Profilage des données : active cette option pour mieux comprendre la distribution et les caractéristiques des données dans chaque colonne.
- Modification des types de données
  - Assure-toi que chaque colonne a le type de données approprié (texte, date, nombre, etc.).
- Gestion des erreurs et nettoyage des données :
  - La plupart des erreurs dans Power Query proviennent de problèmes de format ou de référence. Par exemple, changer un point en virgule pour les nombres décimaux.

3.2 Transformer des données

Il est tout à fait possible de créer des **colonnes personnalisées** et d'effectuer toute sorte d'opérations mathématiques. Par exemple, je peux créer une nouvelle colonne en additionnant deux colonnes entre elles afin d'obtenir un résultat escompté. Cependant, il est important de **s'assurer que les types de données sont compatibles.**
D'autre part, tu vas pouvoir également créer des **colonnes conditionnelles**. Par exemple, si tu veux créer une colonne "taux de change" qui prend en **considération** la devise alors cette fonctionnalité est très utile.

DataBird 2024 ©copyright

3.3 Créer des colonnes à l'aide d'IA

Il y a une méthode plus avancée pour créer des colonnes personnalisées dans Power BI : "Colonne à partir d'exemples". Cette méthode utilise les fonctionnalités **d'intelligence artificielle (IA)** natives de l'outil. Il suffit d'extraire et de reformater des données spécifiques d'une colonne existante.

Avantages de cette méthode :

- Cette méthode évite de rechercher des **formules compliquées** sur internet ou de demander de l'aide externe (comme ChatGPT).
- Elle est présentée comme une solution **gain de temps** et **efficace** pour créer des **colonnes personnalisées complexes**.

3.6 Concaténer des tables

Dans Power BI, une opération similaire à UNION en SQL est utilisée pour concaténer les lignes des deux tables : "Ajouter des requêtes". Cette opération consiste à ajouter les lignes de la seconde table à la suite de la première, en supposant que la structure des colonnes soit identique dans les deux tables.

Après l'union, une **vérification** est faite pour s'assurer que le nombre de colonnes correspond et que les données sont correctement alignées. Si des différences sont détectées, comme des noms de colonnes non correspondants, des **ajustements** sont effectués pour résoudre ces incohérences.

3.5 Merge

"**Fusionner des requêtes**" sur Power Query, c'est l'équivalent d'une jointure en SQL. Tu vas ainsi pouvoir **combiner** des données de **différentes tables** en fonction de **colonnes clés communes**.

DataBird 2024 ©copyright

3.6 Transposer, dépivoter, pivoter

Transposer tes données :

La transposition consiste à convertir les lignes en colonnes et inversement. Cette opération est utile lorsque la structure des données dans un fichier Excel ne correspond pas au format de colonne préféré de Power BI.

Dépivoter tes colonnes :

Le dépivotement transforme des colonnes multiples en une seule colonne. Par exemple, si plusieurs colonnes représentent des catégories différentes (comme différents scénarios de prévisions), le dépivotement crée une seule colonne de "type" avec des lignes correspondant aux valeurs de chaque catégorie.

Pivoter une colonne :

Pivoter une colonne est l'opération inverse du dépivotement. Elle permet de transformer des lignes en colonnes. L'auteur montre comment créer des colonnes distinctes pour différents attributs (comme les prévisions et les soldes de trésorerie) à partir d'une seule colonne d'attributs.

4. Modèle en étoile

Le modèle en étoile est la structure de modélisation **la plus courante** sur Power BI. Une structure de modélisation est ce qui permet de **lier les tables entre elles.**

Le modèle en étoile va **lier les clés primaires des tables dimensionnelles aux clés étrangères de la table factuelle** via des **relations « 1-to-many »**.

DataBird 2024 ©copyright

- **Une table dimensionnelle** est une table dont chaque ligne décrit un item que l'on retrouve dans la table factuelle (par exemple, les informations complémentaires sur un client)
- **Une clé primaire** est une colonne dont chaque ligne est **unique et non-nulle**
- **Une table factuelle** est une table dont chaque ligne représente un événement, souvent marqué dans le temps (par exemple, les facturations effectuées)
- **Une clé étrangère** est une colonne dont chaque ligne n'est pas forcément unique et n'est pas forcément nulle. En revanche, la clé étrangère contient des valeurs qui se réfèrent à une clé primaire
- **Une relation « 1-to-many »** permet de relier une colonne avec des valeurs uniques (clé primaire) à une colonne avec des valeurs multiples (clé étrangère)

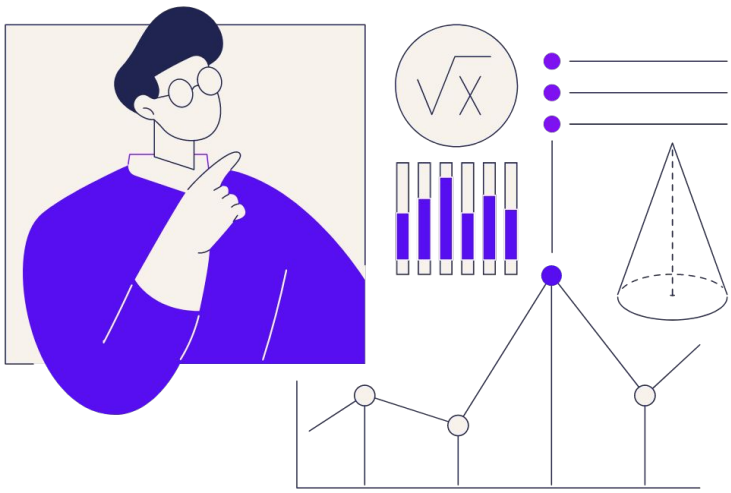

DataBird 2024 ©copyright

DataBird

DataBird 2024 ©copyright